

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

BÁO CÁO MÔN KHAI PHÁ DỮ LIỆU

**KIỂM ĐỊNH TÍNH NGẪU
NHIÊN VÀ DỰ BÁO CHỮ SỐ
XỔ SỐ MIỀN BẮC**

Phân tích thống kê, mô hình xác suất và đánh giá
chiến lược

Sinh viên: Trần Thế Tài

Học phần: Khai phá dữ liệu

Dữ liệu: Kết quả xổ số miền Bắc, 2007-2026

Ngày cập nhật: 09/2026

Nguồn dữ liệu và khả năng tái lập

Nghiên cứu sử dụng dữ liệu kết quả xổ số miền Bắc được lưu trong kho mã KQXS, nhánh `lotery-update`. Mỗi ngày có 27 kết quả giải thưởng; các kết quả được chuẩn hóa thành chuỗi năm chữ số trước khi tạo các biến mục tiêu. Toàn bộ mã phân tích, cấu hình chia tập, bảng CSV và hình minh họa được tổ chức trong cùng kho mã để có thể tái chạy.

Quy trình tái lập gồm: kiểm tra và chuẩn hóa dữ liệu; tạo bảng mục tiêu theo ngày; chạy các script trong thư mục `experiments/p1_statistical_tests`, `experiments/p2_models` và `experiments/p3_strategies`; sau đó biên dịch thư mục báo cáo bằng XeLaTeX. Các mốc thời gian được cố định trước khi đánh giá: giai đoạn phát triển đến hết 2022, validation 2023–2024 và final test 2025–2026.

Báo cáo không xem việc quan sát thấy một sai lệch cục bộ là bằng chứng về tính không ngẫu nhiên của toàn bộ quá trình. Các kết luận được giới hạn trong dữ liệu, định nghĩa mục tiêu, quy tắc trả thưởng và các cấu hình đã kiểm thử.

Tóm tắt

Báo cáo đánh giá một cách có kiểm soát giả thuyết rằng kết quả xổ số miền Bắc có thể chứa tín hiệu đủ ổn định để dự báo chữ số hoặc tạo lợi nhuận. Bộ dữ liệu gồm 191.511 bản ghi giải thưởng trong 7.093 ngày từ 01/01/2007 đến 06/09/2026. Nghiên cứu được tổ chức thành ba phần: (i) kiểm định phân phối, độc lập vị trí, phụ thuộc Markov, phụ thuộc theo độ trễ và tính ổn định theo thời gian; (ii) so sánh các mô hình xác suất, Markov và học máy trên bài toán dự báo chữ số xuất hiện theo từng vị trí; (iii) đánh giá chiến lược tạo vé bằng walk-forward backtest, tách validation 2023–2024 khỏi final test 2025–2026.

Sau hiệu chỉnh Benjamini–Hochberg, phần lớn các kiểm định không bác bỏ giả thuyết ngẫu nhiên; các khác biệt còn lại có quy mô nhỏ và không tạo thành tín hiệu dự báo ổn định. Mô hình Expanding Beta chỉ nhỉnh hơn Uniform rất ít trên final test (Brier 0,104579 so với 0,104589), trong khi mọi cấu hình chiến lược tạo vé được thử đều có ROI âm. Kết quả thực nghiệm vì vậy không ủng hộ việc diễn giải các tần suất lịch sử như một lợi thế dự báo hay một phương án đầu tư có kỳ vọng dương.

Từ khóa: khai phá dữ liệu; kiểm định ngẫu nhiên; xổ số miền Bắc; Brier score; walk-forward backtest; hiệu chỉnh FDR.

Mục lục

Nguồn dữ liệu và khả năng tái lập	i
Tóm tắt	ii
Danh mục viết tắt	v
1 CƠ SỞ LÝ THUYẾT	1
1.1 Bài toán nghiên cứu	1
1.2 Ngẫu nhiên, đồng đều và độc lập	1
1.3 Kiểm định Chi-square, Cramér's V và hiệu chỉnh đa kiểm định	2
1.4 Xích Markov và phụ thuộc theo thời gian	3
1.4.1 Tính chất Markov	3
1.4.2 Markov nhị phân cho sự xuất hiện của chữ số . .	3
1.5 Các mô hình xác suất và tần suất cơ sở	4
1.5.1 Mô hình đồng đều	4
1.5.2 Tần suất mở rộng và cửa sổ trượt	4
1.6 Nền tảng học máy cho bài toán dự báo	5
1.6.1 Học có giám sát và đặc trưng trễ	5
1.6.2 Random Forest	5
1.6.3 Gradient Boosting	5
1.6.4 XGBoost	6
1.6.5 CatBoost	6
1.7 Đánh giá dự báo xác suất	7
1.7.1 Brier score và log loss	7
1.7.2 Calibration và Top- k recall	7
1.8 Đánh giá chiến lược và lợi nhuận	7
2 DỮ LIỆU VÀ QUY TRÌNH PHÂN TÍCH	9
2.1 Dữ liệu	9
2.2 Quy tắc trả thưởng và mục tiêu thực nghiệm	9
2.3 Quy trình	9
2.4 Chống rò rỉ thông tin	10
2.5 Tái lập	10

3 KIỂM ĐỊNH TÍNH NGẪU NHIÊN	11
3.1 Thiết kế giả thuyết và hiệu chỉnh đa kiểm định	11
3.2 Phân phối chữ số và phân phối đuôi số	11
3.3 Độc lập giữa các vị trí	12
3.4 Phụ thuộc Markov và phụ thuộc theo độ trễ	13
3.5 Ổn định theo thời gian và trùng đồng thời	14
3.6 Kết luận P1	16
4 MÔ HÌNH DỰ BÁO CHỮ SỐ	17
4.1 Biến mục tiêu và nguyên tắc đánh giá	17
4.2 Các mô hình	17
4.3 Kết quả định lượng	17
4.4 Diễn giải và giới hạn	20
5 CHIẾN LƯỢC VÀ BACKTEST	22
5.1 Thiết kế chiến lược	22
5.2 Chia tập và chỉ số	22
5.3 Kết quả P3	23
5.4 Chiến lược giải Bảy theo m	24
5.5 Diễn giải	25
6 KẾT QUẢ TỔNG HỢP VÀ THẢO LUẬN	26
6.1 Từ kiểm định đến dự báo	26
6.2 So sánh mô hình	26
6.3 Ý nghĩa thực tiễn	26
6.4 Hạn chế	26
7 KẾT LUẬN	28
TÀI LIỆU THAM KHẢO	29

Danh mục viết tắt

Ký hiệu	Diễn giải
FDR	False Discovery Rate, tỷ lệ phát hiện sai
H_0	Giả thuyết không
IID	Independent and identically distributed
CDM	Categorical/Dirichlet-Multinomial
RF	Random Forest
LL	Log loss
ROI	Return on Investment
P1, P2, P3	Ba phần thực nghiệm của nghiên cứu

Danh sách hình vẽ

3.1	Phân phối chữ số theo vị trí trong toàn bộ dữ liệu. . . .	12
3.2	Mức phụ thuộc giữa các vị trí chữ số.	13
3.3	Độ lệch của ma trận chuyển trạng thái Markov lag 1. .	14
3.4	Phụ thuộc theo độ trễ 1-30 ngày bằng Cramér's V. . . .	14
3.5	Kết quả kiểm định gộp trong phân tích ổn định theo thời gian.	15
3.6	Độ ổn định của các thống kê theo giai đoạn.	15
3.7	Tỷ lệ trùng đồng thời nhiều giải theo năm.	16
4.1	So sánh Brier score trên validation.	18
4.2	Brier score theo mô hình.	19
4.3	Brier score theo vị trí chữ số.	19
4.4	Độ bao phủ Top- k theo vị trí.	19
4.5	Đường calibration được dựng lại từ calibration.csv. . . .	20
4.6	Phân phối thứ hạng chữ số thực tế.	20
5.1	Lợi nhuận tích lũy của các pool trên validation.	23
5.2	Lợi nhuận tích lũy của các pool trên final test.	23
5.3	Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên validation.	24
5.4	Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên final test.	24
5.5	Độ nhảy lợi nhuận theo số đuôi m trên validation.	25
5.6	Độ nhảy lợi nhuận theo số đuôi m trên final test.	25

Danh sách bảng

3.1	Số kiểm định và kết quả sau hiệu chỉnh FDR	11
4.1	Brier score và log loss trên validation 2023-2024	18
5.1	Backtest các cấu hình pool năm chữ số	23

Chương 1

CƠ SỞ LÝ THUYẾT

1.1 Bài toán nghiên cứu

Mỗi ngày, xổ số kiến thiết miền Bắc công bố nhiều kết quả thuộc các hạng giải khác nhau. Trong nghiên cứu này, mỗi kết quả được biểu diễn theo các chữ số ở từng vị trí, từ hàng chục nghìn đến hàng đơn vị khi vị trí tương ứng tồn tại. Hai nhóm câu hỏi được đặt ra. Thứ nhất, dữ liệu lịch sử có cung cấp bằng chứng thống kê về sự lệch khỏi cơ chế ngẫu nhiên, tính độc lập theo vị trí hoặc tính độc lập theo thời gian hay không. Thứ hai, nếu tồn tại các sai lệch nhỏ trong phân phối thực nghiệm, liệu chúng có đủ ổn định để các mô hình xác suất và học máy cải thiện dự báo ngoài mẫu và hỗ trợ xây dựng chiến lược có hiệu quả kinh tế hay không.

Đối với bài toán dự báo theo ngày, tại mỗi vị trí j và chữ số $d \in \{0, \dots, 9\}$, biến mục tiêu nhị phân được định nghĩa

$$Y_{t,j,d} = \begin{cases} 1, & \text{nếu chữ số } d \text{ xuất hiện tại vị trí } j \text{ trong ngày } t, \\ 0, & \text{ngược lại.} \end{cases}$$

Như vậy, bài toán dự báo chính có thể xem là bài toán multi-label gồm $5 \times 10 = 50$ mục tiêu nhị phân. Mô hình không chỉ đưa ra nhãn dự báo mà quan trọng hơn là ước lượng xác suất $\hat{p}_{t,j,d} = P(Y_{t,j,d} = 1 \mid \mathcal{F}_{t-1})$, trong đó $\mathcal{F}_{t-1}$ biểu diễn toàn bộ thông tin hợp lệ trước ngày dự báo.

1.2 Ngẫu nhiên, đồng đều và độc lập

Một chuỗi kết quả phù hợp với cơ chế ngẫu nhiên cơ bản khi phân phối chữ số không khác đáng kể so với phân phối kỳ vọng, quan hệ giữa các vị trí đủ yếu, kết quả trong quá khứ không tạo ra khả năng dự báo có hệ thống cho tương lai và các đặc trưng phân phối tương đối ổn định theo thời gian. Các khái niệm này cần được phân biệt: phân phối biên gần đồng đều không đồng nghĩa với độc lập, và độc lập giữa các vị trí không đảm bảo độc lập theo thời gian.

1.3. KIỂM ĐỊNH CHI-SQUARE, CRAMÉR'S V VÀ HIỆU CHỈNH ĐA KIỂM ĐỊNH

Trong kiểm định giả thuyết, việc không bác bỏ H_0 không phải là bằng chứng tuyệt đối rằng chuỗi hoàn toàn ngẫu nhiên; nó chỉ cho thấy dữ liệu hiện có chưa cung cấp đủ bằng chứng thống kê để bác bỏ giả thuyết không. Ngược lại, một sai lệch có ý nghĩa thống kê cũng chưa đồng nghĩa với khả năng dự báo hoặc khả năng sinh lợi thực tế. Vì vậy, báo cáo tách biệt ba lớp đánh giá: ý nghĩa thống kê, chất lượng dự báo ngoài mẫu và hiệu quả của chiến lược backtest.

1.3 Kiểm định Chi-square, Cramér's V và hiệu chỉnh đa kiểm định

Với tần suất quan sát O_k và tần suất kỳ vọng E_k , thống kê Pearson Chi-square được xác định bởi

$$\chi^2 = \sum_{k=1}^K \frac{(O_k - E_k)^2}{E_k}.$$

Kiểm định này được sử dụng để đánh giá mức độ phù hợp với phân phối kỳ vọng hoặc sự độc lập giữa các biến phân loại. Tuy nhiên, khi kích thước mẫu lớn, một khác biệt rất nhỏ cũng có thể tạo ra p -value thấp. Do đó, bên cạnh ý nghĩa thống kê cần báo cáo kích thước hiệu ứng.

Đối với hai biến phân loại, Cramér's V được dùng như một thước đo cường độ phụ thuộc:

$$V = \sqrt{\frac{\chi^2}{N \min(r-1, c-1)}},$$

trong đó N là số quan sát, r và c lần lượt là số hàng và số cột của bảng chéo. Giá trị V gần 0 cho thấy quan hệ thực nghiệm yếu, ngay cả khi kiểm định Chi-square có thể đạt ý nghĩa thống kê.

Do nghiên cứu thực hiện đồng thời nhiều kiểm định trên các vị trí, giải và độ trễ khác nhau, sử dụng trực tiếp ngưỡng $p < 0.05$ làm tăng nguy cơ phát hiện giả. Báo cáo áp dụng thủ tục Benjamini-Hochberg và sử dụng $q < 0.05$ để kiểm soát false discovery rate (FDR).

1.4 Xích Markov và phụ thuộc theo thời gian

1.4.1 Tính chất Markov

Xích Markov là mô hình xác suất cho một quá trình mà phân phối của trạng thái kế tiếp, khi biết trạng thái hiện tại, không phụ thuộc trực tiếp vào toàn bộ lịch sử trước đó. Với xích Markov bậc một,

$$P(X_t = x_t \mid X_{t-1}, X_{t-2}, \dots, X_0) = P(X_t = x_t \mid X_{t-1}).$$

Nếu không gian trạng thái gồm các chữ số $\{0, 1, \dots, 9\}$, xác suất chuyển từ trạng thái i sang j được ký hiệu

$$p_{ij} = P(X_t = j \mid X_{t-1} = i),$$

và ma trận chuyển trạng thái là

$$\mathbf{P} = (p_{ij})_{10 \times 10}, \quad \sum_{j=0}^9 p_{ij} = 1.$$

Nếu kết quả giữa hai ngày thực sự độc lập, phân phối điều kiện theo trạng thái ngày trước không nên khác có hệ thống so với phân phối biên. Vì vậy, phân tích ma trận chuyển và kiểm định theo từng vị trí cung cấp một cách trực tiếp để kiểm tra dấu hiệu phụ thuộc thời gian bậc một.

1.4.2 Markov nhị phân cho sự xuất hiện của chữ số

Trong phần dự báo, nghiên cứu sử dụng biến trạng thái nhị phân cho từng cặp vị trí-chữ số: $Y_t \in \{0, 1\}$ cho biết chữ số đó có xuất hiện trong ngày hay không. Khi đó mô hình Markov ước lượng hai xác suất chính

$$P(Y_t = 1 \mid Y_{t-1} = 1), \quad P(Y_t = 1 \mid Y_{t-1} = 0).$$

Để tránh xác suất bằng 0 hoặc 1 do số lần chuyển trạng thái hữu hạn, xác suất được làm trơn Laplace. Chẳng hạn,

$$\hat{p}_{1 \rightarrow 1} = \frac{N_{11} + 1}{N_{10} + N_{11} + 2},$$

trong đó N_{ab} là số lần quan sát chuyển từ trạng thái a sang b . Có thể diễn giải phép làm trơn này dưới góc nhìn Bayes với tiên nghiệm

Beta(1, 1) cho mỗi xác suất chuyển nhị phân. Mô hình Markov vì vậy vừa là một baseline dự báo, vừa là phép kiểm tra thực nghiệm xem thông tin ngày liền trước có tạo ra cải thiện so với mô hình không điều kiện hay không.

1.5 Các mô hình xác suất và tần suất cơ sở

1.5.1 Mô hình đồng đều

Uniform baseline mô tả giả thuyết không có chữ số nào được ưu tiên. Khi một vị trí nhận m_j lượt quay hợp lệ trong ngày và mỗi lượt có xác suất 0.1 cho một chữ số cụ thể, xác suất chữ số đó xuất hiện ít nhất một lần là

$$p_j = 1 - (1 - 0.1)^{m_j} = 1 - 0.9^{m_j}.$$

Đây là mốc tham chiếu quan trọng: một mô hình phức tạp chỉ có giá trị dự báo khi cải thiện ổn định so với baseline đơn giản trên dữ liệu ngoài mẫu.

1.5.2 Tần suất mở rộng và cửa sổ trượt

Với một mục tiêu nhị phân Y_t , expanding frequency sử dụng toàn bộ lịch sử hợp lệ trước thời điểm dự báo:

$$\hat{p}_t = \frac{1}{t-1} \sum_{s < t} Y_s.$$

Rolling frequency chỉ sử dụng w quan sát gần nhất,

$$\hat{p}_t^{(w)} = \frac{1}{w} \sum_{s=t-w}^{t-1} Y_s.$$

Cửa sổ dài tạo ước lượng ổn định hơn nhưng phản ứng chậm với thay đổi; cửa sổ ngắn nhạy hơn với biến động gần đây nhưng có phương sai lớn hơn. Việc so sánh nhiều độ dài cửa sổ do đó giúp kiểm tra liệu dữ liệu có chứa tính không dừng hoặc tín hiệu ngắn hạn đủ mạnh để dự báo hay không.

1.6 Nền tảng học máy cho bài toán dự báo

1.6.1 Học có giám sát và đặc trưng trễ

Các mô hình học máy trong nghiên cứu thuộc nhóm học có giám sát. Từ dữ liệu lịch sử, thuật toán học một ánh xạ

$$f : \mathbf{x}_t \mapsto \hat{p}_t,$$

trong đó $\mathbf{x}_t$ chỉ chứa thông tin có sẵn trước thời điểm t . Các đặc trưng chính gồm trạng thái xuất hiện của chữ số tại các độ trễ 1, 2, 3, 7, 14 và 30 ngày cùng một số biến lịch dạng chu kỳ. Việc dịch trễ đặc trưng đảm bảo không sử dụng kết quả của ngày cần dự báo.

Vì đây là dữ liệu theo thời gian, chia ngẫu nhiên train/test có thể gây rò rỉ thông tin và đánh giá quá lạc quan. Nghiên cứu do đó sử dụng chia tập theo thời gian: mô hình chỉ được huấn luyện trên giai đoạn quá khứ, lựa chọn cấu hình trên validation và đánh giá chiến lược cuối cùng trên giai đoạn tương lai chưa được dùng để lựa chọn mô hình.

1.6.2 Random Forest

Random Forest là phương pháp ensemble kết hợp nhiều cây quyết định. Mỗi cây được xây dựng từ mẫu bootstrap và chỉ xem xét một tập con đặc trưng tại mỗi phép chia. Với bài toán phân loại, xác suất cuối cùng có thể thu được bằng cách tổng hợp xác suất từ các cây:

$$\hat{p}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{p}_b(\mathbf{x}),$$

trong đó B là số cây. Cơ chế lấy mẫu và ngẫu nhiên hóa đặc trưng giúp giảm tương quan giữa các cây và thường làm giảm phương sai so với một cây quyết định đơn. Trong nghiên cứu, Random Forest đóng vai trò mô hình ML cơ sở để kiểm tra liệu quan hệ phi tuyến giữa các đặc trưng trễ có tạo ra thông tin dự báo ngoài mẫu hay không.

1.6.3 Gradient Boosting

Khác với Random Forest xây dựng nhiều cây tương đối độc lập, gradient boosting xây dựng mô hình theo trình tự. Ở vòng lặp m ,

một cây mới được thêm vào để giảm phần sai số còn lại của tổ hợp hiện tại:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta f_m(\mathbf{x}),$$

trong đó η là learning rate. Nhờ quá trình cộng dồn các weak learners, boosting có khả năng biểu diễn các quan hệ phi tuyến và tương tác phức tạp giữa các đặc trưng. Tuy nhiên, độ sâu cây, learning rate, số vòng boosting và regularization phải được kiểm soát để hạn chế overfitting.

1.6.4 XGBoost

XGBoost là một biến thể gradient-boosted trees có hàm mục tiêu tổng quát

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t)}) + \sum_{k=1}^t \Omega(f_k),$$

trong đó l là hàm mất mát và $\Omega(f_k)$ là thành phần regularization cho độ phức tạp của cây. Đối với mục tiêu nhị phân của nghiên cứu, mô hình tối ưu binary logistic loss và trả về xác suất xuất hiện của từng chữ số. Các cơ chế shrinkage, subsampling, column sampling và regularization giúp cân bằng giữa khả năng học quan hệ phức tạp và nguy cơ khớp nhiễu trong dữ liệu xố số.

1.6.5 CatBoost

CatBoost cũng thuộc họ gradient boosting trên cây quyết định. Thuật toán phát triển các cơ chế như ordered boosting nhằm giảm prediction shift và hạn chế một số dạng overfitting trong quá trình boosting. Trong bài toán này, CatBoost được sử dụng như một mô hình phi tuyến độc lập để đối chiếu với XGBoost trên cùng tập đặc trưng và cùng giao thức chia thời gian. Do dữ liệu đầu vào của thí nghiệm chủ yếu là đặc trưng số và nhị phân, mục tiêu so sánh không nằm ở khả năng xử lý biến phân loại đặc trưng của CatBoost mà ở khả năng học hàm xác suất khác nhau của hai thuật toán boosting.

1.7 Đánh giá dự báo xác suất

1.7.1 Brier score và log loss

Với dự báo xác suất $\hat{p}_i$ và nhãn $y_i \in \{0, 1\}$, Brier score được định nghĩa

$$\text{BS} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y_i)^2.$$

Brier score càng thấp càng tốt và đánh giá trực tiếp độ chính xác của xác suất. Log loss được xác định bởi

$$\text{LL} = -\frac{1}{n} \sum_{i=1}^n [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)].$$

Log loss phạt mạnh các dự báo tự tin nhưng sai. Vì mục tiêu cuối cùng cần xếp hạng chữ số và xây dựng chiến lược từ xác suất, hai thước đo này phù hợp hơn việc chỉ sử dụng accuracy tại một ngưỡng phân loại cố định.

1.7.2 Calibration và Top- k recall

Một mô hình được xem là hiệu chỉnh tốt nếu trong nhóm các dự báo có xác suất xấp xỉ p , tỷ lệ xảy ra quan sát được cũng xấp xỉ p . Calibration vì vậy trả lời câu hỏi khác với ranking: mô hình có thể xếp hạng tốt nhưng xác suất dự báo vẫn quá cao hoặc quá thấp.

Đối với mỗi vị trí, các chữ số được sắp giảm dần theo xác suất. Top- k recall đo tỷ lệ chữ số thực tế được bao phủ bởi k lựa chọn có xác suất cao nhất. Chỉ số này nổi trội tiếp phân dự báo với phân chiến lược, bởi số lượng chữ số được giữ lại tại từng vị trí quyết định kích thước không gian vé ứng viên và chi phí đầu tư.

1.8 Đánh giá chiến lược và lợi nhuận

Đối với một chiến lược mua tập vé S_t trong ngày t , lợi nhuận được tính tổng quát bởi

$$\Pi_t = R_t(S_t) - c|S_t|,$$

trong đó c là giá mỗi vé, $|S_t|$ là số vé mua và $R_t(S_t)$ là tổng tiền thưởng thực tế theo toàn bộ các quy tắc giải mà các vé trong S_t đạt được.

Tỷ suất hoàn vốn được tính

$$\text{ROI} = \frac{\sum_t \Pi_t}{\sum_t c|S_t|}.$$

Do cơ cấu giải thưởng phụ thuộc số chữ số khớp và loại giải, không sử dụng một mức thưởng cố định cho mọi lần trúng. Việc đánh giá chiến lược phải thực hiện trên giai đoạn ngoài mẫu, đồng thời xem xét lợi nhuận tích lũy, ROI, tần suất trúng và mức biến động thay vì kết luận từ một vài ngày có giải thưởng lớn.

Tách biệt giai đoạn lựa chọn chiến lược và giai đoạn final test là điều kiện quan trọng để hạn chế selection bias. Một cấu hình có lợi nhuận cao trên validation chỉ được xem là có bằng chứng thực nghiệm mạnh hơn khi tiếp tục duy trì kết quả trên giai đoạn final test chưa tham gia vào quá trình lựa chọn.

Chương 2

DỮ LIỆU VÀ QUY TRÌNH PHÂN TÍCH

2.1 Dữ liệu

Dữ liệu gồm 191 511 dòng kết quả, 7 093 ngày, từ 01/01/2007 đến 06/09/2026. Tập dữ liệu bao phủ 27 giải mỗi ngày, gồm Đặc biệt, giải Nhất đến giải Bảy. Kết quả được chuẩn hóa theo ngày, giải và vị trí; các chuỗi ngắn được bổ sung số 0 ở đầu để bảo toàn độ dài. Hai chữ số cuối được giữ trong miền 00, ..., 99.

2.2 Quy tắc trả thưởng và mục tiêu thực nghiệm

Mỗi vé được biểu diễn bởi một số có năm chữ số. Giải Đặc biệt, giải Nhất, Nhì và Ba yêu cầu khớp đủ năm chữ số; giải Tư và Năm khớp bốn chữ số; giải Sáu khớp ba chữ số; giải Bảy khớp hai chữ số. Phụ Đặc biệt và Khuyến khích Đặc biệt được xử lý theo quy định riêng, trong đó ký hiệu của giải Đặc biệt không được dùng làm đặc trưng dự báo. Một vé có thể đồng thời nhận nhiều giải khi các điều kiện hậu tố cùng thỏa mãn.

Mục tiêu được chia thành hai lớp: (i) dự báo pool chữ số theo từng vị trí, tức chữ số nào có khả năng xuất hiện trong 27 giải; (ii) dự báo trực tiếp số năm chữ số theo từng giải, chủ yếu để đánh giá tính khả thi và mức độ khó của bài toán.

2.3 Quy trình

1. Kiểm tra ngày, bản ghi trùng và tính hợp lệ.
2. Tách chữ số theo vị trí và tạo biến đuôi số.
3. Phân tích phân phối, độc lập theo vị trí và phụ thuộc thời gian.
4. Kiểm tra ổn định theo các giai đoạn.
5. Tạo mục tiêu theo ngày: chữ số bằng 1 nếu xuất hiện trong ít nhất một của 27 kết quả.

6. Huấn luyện/cập nhật mô hình theo walk-forward.
7. Đánh giá Brier, log loss, top- k , calibration, thứ hạng và lợi nhuận.

2.4 Chống rò rỉ thông tin

Dự báo ngày t chỉ sử dụng dữ liệu trước t ; kết quả ngày t chỉ cập nhật mô hình sau khi dự báo được tạo. Validation 2023–2024 dùng để so sánh và khóa cấu hình. Final test 2025–2026 chỉ dùng cho đánh giá cuối cùng và không được dùng để chọn lại mô hình hay chiến lược.

2.5 Tái lập

Mã nguồn nằm trong `experiments/`; kết quả được tổ chức tương ứng trong `artifacts/p1_statistical_tests/`, `artifacts/p2_models/` và `artifacts/p3_strategies/`.

Chương 3

KIỂM ĐỊNH TÍNH NGẪU NHIÊN

3.1 Thiết kế giả thuyết và hiệu chỉnh đa kiểm định


Phần P1 kiểm tra liệu dữ liệu có lệch khỏi các mô hình ngẫu nhiên cơ bản hay không. Mỗi nhóm kiểm định được thực hiện trên dữ liệu gộp và/hoặc theo vị trí chữ số, sau đó p-value được hiệu chỉnh bằng thủ tục Benjamini-Hochberg với ngưỡng $q < 0,05$. Cách làm này hạn chế kết luận sai do số lượng kiểm định lớn.

Bảng 3.1. Số kiểm định và kết quả sau hiệu chỉnh FDR

Nhóm kiểm định	Số kiểm định	Bác bỏ H_0
Phân phối chữ số	45	1
Phân phối đuôi số	28 hợp lệ	5
Độc lập giữa vị trí	90	0
Markov lag 1	90	0
Phụ thuộc lag 1-30	2700	0
Ổn định theo giai đoạn	4050	0

3.2 Phân phối chữ số và phân phối đuôi số


Kiểm định χ^2 được dùng để so sánh tần suất chữ số quan sát với phân phối đều. Hình 3.1 cho thấy các sai khác biên trong dữ liệu gộp; chỉ một trong 45 kiểm định còn ý nghĩa sau FDR. Với các đuôi số, chỉ 28 kiểm định đủ điều kiện và có 5 bác bỏ H_0 . Đây là các phát hiện cục bộ, chưa đủ để kết luận tồn tại quy luật tổng quát.



Hình 3.1. Phân phối chữ số theo vị trí trong toàn bộ dữ liệu.

3.3 Độc lập giữa các vị trí


Kiểm định độc lập và thống kê liên hợp được dùng để xem chữ số ở các vị trí có liên hệ vượt quá mức kỳ vọng hay không. Không có bác bỏ nào trong 90 kiểm định sau FDR. Hình 3.2 trực quan hóa mức phụ thuộc rất nhỏ giữa các vị trí.




Hình 3.2. Mức phụ thuộc giữa các vị trí chữ số.

3.4 Phụ thuộc Markov và phụ thuộc theo độ trễ

P1 kiểm tra cả phụ thuộc chuyển trạng thái ở lag 1 và phụ thuộc giữa các ngày ở lag 1–30. Không có kiểm định Markov nào trong 90 kiểm định bị bác bỏ; hình 3.3 cho thấy độ lệch chuyển trạng thái không tạo cấu trúc nổi bật. Tương tự, thống kê Cramér's V theo các độ trễ không cho thấy tín hiệu bền vững (Hình 3.4).




Hình 3.3. Độ lệch của ma trận chuyển trạng thái Markov lag 1.




Hình 3.4. Phụ thuộc theo độ trễ 1-30 ngày bằng Cramér's V.

3.5 Ổn định theo thời gian và trúng đồng thời


Phân tích ổn định chia chuỗi theo giai đoạn và lặp lại các kiểm định chính. Không có bác bỏ nào trong 4050 kiểm định; Hình 3.6 tóm tắt kết quả ý nghĩa theo từng nhóm. Tỷ lệ ngày có ít nhất hai giải cùng chứa một đuôi số là 62,63%; ít nhất ba giải là 0,25%; ít nhất bốn giải xấp xỉ 0,00%. Đây là mô tả cơ chế chồng lấn của nhiều giải, không phải bằng chứng dự báo.



Hình 3.5. Kết quả kiểm định gộp trong phân tích ổn định theo thời gian.



Hình 3.6. Độ ổn định của các thống kê theo giai đoạn.



Hình 3.7. Tỷ lệ trùng đồng thời nhiều giải theo năm.

3.6 Kết luận P1

Các kiểm định cung cấp bằng chứng nhất quán với một quá trình gần ngẫu nhiên ở mức độ cần thiết cho dự báo thực hành. Một vài sai lệch cục bộ có thể xuất hiện do kích thước mẫu lớn, do cơ chế nhiều giải trong cùng ngày hoặc do biến thiên ngẫu nhiên. Vì vậy, P1 chỉ cho phép chuyển sang kiểm tra dự báo ngoài mẫu; không cho phép khẳng định có lợi thế chơi.

Chương 4

MÔ HÌNH DỰ BÁO CHỮ SỐ

4.1 Biến mục tiêu và nguyên tắc đánh giá

Với mỗi ngày, vị trí và chữ số, mục tiêu bằng 1 nếu chữ số xuất hiện trong ít nhất một của 27 kết quả, bằng 0 nếu không xuất hiện. Như vậy, P2 là bài toán phân loại nhị phân nhiều đầu ra với 50 nhãn, không phải bài toán đoán một số duy nhất từ 00 đến 99.

Dữ liệu phát triển kết thúc năm 2022; validation gồm 723 ngày của 2023–2024; final test gồm 606 ngày của 2025–2026. Các thước đo chính là Brier score và log loss trên 50 nhãn. Các chỉ số Top- k được tính trên thứ hạng chữ số trong từng vị trí; do mỗi vị trí có thể có nhiều chữ số xuất hiện, Top- k không được diễn giải như xác suất trúng một vé cụ thể.

4.2 Các mô hình

Đường cơ sở Uniform-27-IID dùng xác suất lý thuyết $1 - (9/10)^{27}$ cho mọi chữ số ở mọi vị trí. Nhóm thống kê gồm Expanding Beta, Rolling Beta với cửa sổ 30, 90 và 365 ngày, Dirichlet daily và Markov presence. Nhóm học máy gồm Random Forest, CatBoost và XGBoost. Tất cả mô hình được chạy walk-forward: dự báo ngày t chỉ dùng thông tin trước t .


4.3 Kết quả định lượng


Bảng 4.1 sử dụng trực tiếp các giá trị trong `model_summary.csv`, được sinh từ pipeline đánh giá 50 nhãn. Do đó, các con số trong bảng được làm tròn từ CSV thay vì sao chép mô tả văn bản cũ.

Bảng 4.1. Brier score và log loss trên validation 2023-2024


Mô hình	Brier score	Log loss
Uniform-27-IID	0,106336	0,356877
Expanding Beta	0,106351	0,356916
Rolling Beta 365	0,106527	0,357810
Dirichlet daily	0,106341	0,356877
Markov presence	0,106389	0,357095
Random Forest	0,107159	0,360805
CatBoost	0,106763	0,358974
XGBoost	0,108023	0,364530
Rolling Beta 90	0,107390	0,361708
Rolling Beta 30	0,109681	0,369545

Trên validation, Dirichlet daily gần như tương đương Uniform và Expanding Beta; CatBoost là mô hình học máy tốt nhất nhưng vẫn kém nhóm cơ sở theo Brier. Trên final test, Expanding Beta đạt Brier 0,104579 và log loss 0,351395, còn Uniform đạt 0,104589 và 0,351453. Khoảng cách rất nhỏ, không phải bằng chứng về lợi thế kinh tế.


**Hình 4.1.** So sánh Brier score trên validation.




Hình 4.2. Brier score theo mô hình.




Hình 4.3. Brier score theo vị trí chữ số.



Hình 4.4. Độ bao phủ Top- k theo vị trí.



Hình 4.5. Đường calibration được dựng lại từ calibration.csv.



Hình 4.6. Phân phối thứ hạng chữ số thực tế.

4.4 Diễn giải và giới hạn

Các đường Top- k gần đường cơ sở lý thuyết: Top 1 bao phủ xấp xỉ 10%, Top 3 khoảng 30%, Top 5 khoảng 50%. Điều này là hệ quả tự nhiên của mười chữ số gần đối xứng, không cho thấy mô hình nhận diện được chữ số “sắp ra”. Mô hình có Brier thấp hơn rất ít vẫn có

thể không tạo được lợi nhuận sau khi tính chi phí, số lượng vé và cơ cấu trả thưởng.

Chương 5

CHIẾN LƯỢC VÀ BACKTEST

5.1 Thiết kế chiến lược

P3 chuyển xác suất chữ số thành các pool năm vị trí, rồi sinh vé bằng tích Descartes. Ba cấu hình được kiểm thử là $2 \times 2 \times 2 \times 2 \times 2 = 32$ vé, $3 \times 2 \times 2 \times 2 \times 1 = 24$ vé và $3 \times 3 \times 2 \times 1 \times 1 = 18$ vé mỗi ngày. Một nhánh riêng tập trung vào giải Bảy: chọn các tiền tố đứng đầu ở ba vị trí đầu và thử $m = 1, \dots, 10$ đuôi số đứng đầu ở hai vị trí cuối.

Mỗi vé có giá 10.000 VND. Kết quả được đối sánh với toàn bộ 27 giải năm chữ số trong ngày; một vé có thể nhận nhiều giải hợp lệ. Mức trả trong code backtest là: Phụ Đặc biệt 25.000.000; Khuyến khích Đặc biệt 40.000; giải Nhất 10.000.000; Nhì 5.000.000; Ba 1.000.000; Tư 400.000; Năm 200.000; Sáu 100.000; Bảy 40.000 VND.

5.2 Chia tập và chỉ số

Validation 2023–2024 dùng để so sánh ứng viên; final test 2025–2026 chỉ được mở một lần cho đánh giá cuối. Lợi nhuận ngày là


$$\Pi_t = \sum_{g \in G_t} R_g - 10\,000n_t,$$

trong đó G_t là tập giải vé nhận được, R_g là tiền trả của giải và n_t là số vé. ROI bằng tổng lợi nhuận chia tổng chi phí. Cách tính này tránh áp dụng một công thức hòa vốn duy nhất cho các chiến lược có cơ cấu giải khác nhau.


5.3 Kết quả P3

Bảng 5.1. Backtest các cấu hình pool năm chữ số

Fold	Cấu hình	Số ngày	Số vé	Lợi nhuận (VND)	ROI
Validation	32 vé	723	23136	-143.600.000	-62,07%
Validation	24 vé	723	17352	-134.120.000	-77,29%
Validation	18 vé	723	13014	-104.580.000	-80,36%
Final test	32 vé	606	19392	-147.120.000	-75,87%
Final test	24 vé	606	14544	-110.000.000	-75,63%
Final test	18 vé	606	10908	-86.940.000	-79,70%




Hình 5.1. Lợi nhuận tích lũy của các pool trên validation.




Hình 5.2. Lợi nhuận tích lũy của các pool trên final test.

5.4 Chiến lược giải Bảy theo m

Kết quả theo m được giữ lại như một thí nghiệm độ nhạy. Việc tăng m làm tăng số lựa chọn và chi phí, nhưng không bảo đảm tăng lợi nhuận; do đó, cấu hình tốt nhất phải được khóa từ validation trước khi xem final test.




Hình 5.3. Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên validation.



Hình 5.4. Lợi nhuận tích lũy của chiến lược tập trung giải Bảy trên final test.



Hình 5.5. Độ nhạy lợi nhuận theo số đuôi m trên validation.



Hình 5.6. Độ nhạy lợi nhuận theo số đuôi m trên final test.

5.5 Diễn giải

Tất cả cấu hình đều có ROI âm trên cả hai giai đoạn. Cấu hình 32 vé có tỷ lệ ngày có ít nhất một lần trúng cao hơn, nhưng chi phí cũng lớn hơn và tổng lợi nhuận vẫn âm. Đây là bằng chứng trực tiếp rằng một cải thiện nhỏ về thứ hạng chữ số trong P2 không chuyển thành lợi thế kinh tế trong cơ chế trả thưởng được mô phỏng.

Chương 6

KẾT QUẢ TỔNG HỢP VÀ THẢO LUẬN

6.1 Từ kiểm định đến dự báo

Phần 1 không tìm thấy phụ thuộc thời gian có hệ thống sau hiệu chỉnh nhiều kiểm định. Vì vậy, mô hình dự báo được xem là phép kiểm tra thực nghiệm về khả năng cải thiện ngoài mẫu, không phải giả định rằng dữ liệu chắc chắn có quy luật.

6.2 So sánh mô hình

Expanding Beta đứng đầu validation, trong khi CatBoost là mô hình học máy tốt nhất. Tuy nhiên chênh lệch giữa Expanding Beta và Uniform trên final test rất nhỏ. Top- k cao ở k lớn một phần do mục tiêu pool có độ phủ nhiều chữ số; không nên diễn giải như mô hình đã dự đoán chính xác một số năm chữ số.

Đối với mục tiêu giải, xác suất trúng một vé cụ thể nhỏ hơn rất nhiều so với xác suất một chữ số xuất hiện trong toàn bộ 27 giải. Vì vậy, báo cáo tách hai mục tiêu và chỉ sử dụng pool prediction để hỗ trợ sinh ứng viên, sau đó đánh giá trực tiếp vé theo kết quả thực tế và quy tắc trả thưởng.

6.3 Ý nghĩa thực tiễn

Lợi nhuận dương trong một giai đoạn không đủ chứng minh lợi thế dài hạn. Nếu kết quả không tái lập ở giai đoạn khác, kết luận phù hợp là hiệu năng chưa ổn định. Cần báo cáo khoảng tin cậy, nhiều giai đoạn rolling và số lần thử chiến lược.

6.4 Hạn chế

- Cách định nghĩa mục tiêu theo 27 kết quả ảnh hưởng mạnh đến độ khó.

- Nhiều kiểm định và cấu hình làm tăng nguy cơ dương tính giả.
- Final test chỉ phản ánh dữ liệu đã thu thập đến thời điểm báo cáo.
- Lợi nhuận mẫu nhỏ có thể bị chi phối bởi một vài lần trúng.

Chương 7

KẾT LUẬN

Báo cáo đã xây dựng quy trình gồm kiểm định thống kê, mô hình xác suất và backtest chiến lược cho dữ liệu xổ số miền Bắc. Quy trình walk-forward và tách validation khỏi final test giúp hạn chế rò rỉ thông tin.

Các kiểm định không cho thấy bằng chứng mạnh về phụ thuộc vị trí, Markov hoặc phụ thuộc thời gian ở lag 1–30 sau hiệu chỉnh FDR. Một số sai lệch cục bộ trong phân phối chữ số và đuôi số tồn tại, nhưng chưa đủ để suy ra quy luật dự báo tổng quát.

Expanding Beta là mô hình tốt nhất trên validation theo Brier score và log loss; trên final test, lợi thế so với Uniform rất nhỏ. Các mô hình học máy không vượt rõ rệt các baseline xác suất đơn giản.

Kết luận cuối cùng là chưa có bằng chứng đủ mạnh để khẳng định chiến lược có lợi nhuận bền vững. Lợi nhuận của một giai đoạn chỉ là kết quả backtest có điều kiện; cần khóa cấu hình trước, mở rộng final test và kiểm tra khả năng tái lập ở nhiều giai đoạn.

Nghiên cứu không nhằm khuyến khích đặt cược, mà nhằm kiểm tra bằng phương pháp thống kê liệu dữ liệu có chứa tín hiệu ổn định vượt baseline hay không.

TÀI LIỆU THAM KHẢO

- [1] Benjamini, Y. and Hochberg, Y. (1995), Controlling the false discovery rate, *JRSS Series B*, 57(1), 289–300. [2] Gelman, A. et al. (2013), *Bayesian Data Analysis*, 3rd ed., CRC Press. [3] Bishop, C. M. (2006), *Pattern Recognition and Machine Learning*, Springer. [4] Breiman, L. (2001), Random forests, *Machine Learning*, 45, 5–32. [5] Chen, T. and Guestrin, C. (2016), XGBoost: A scalable tree boosting system, *Proceedings of KDD*. [6] Prokhorenkova, L. et al. (2018), CatBoost: unbiased boosting with categorical features, *NeurIPS*. [7] Gneiting, T. and Raftery, A. E. (2007), Strictly proper scoring rules, prediction, and estimation, *JASA*. [8] Dawid, A. P. (1982), The well-calibrated Bayesian, *JASA*. [9] Repository KQXS, nhánh lottery-update, GitHub, truy cập 09/2026. [10] Repository template qh25-data-mining/report, GitHub, truy cập 09/2026.